Car Insurance Claim Risk Prediction

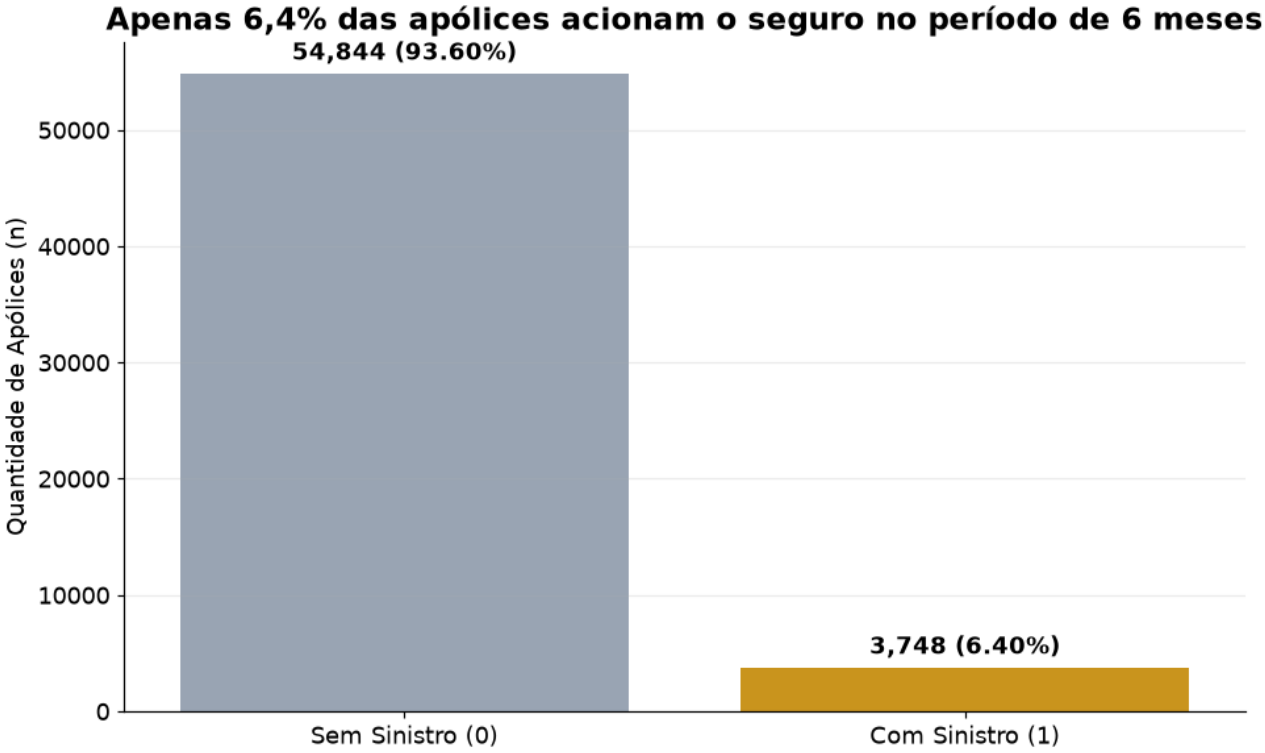
Relatório técnico — EDA, modelagem (GLM e árvore/boosting) e arquitetura MLOps

Gerado automaticamente a partir de notebooks/, output/ e img/.

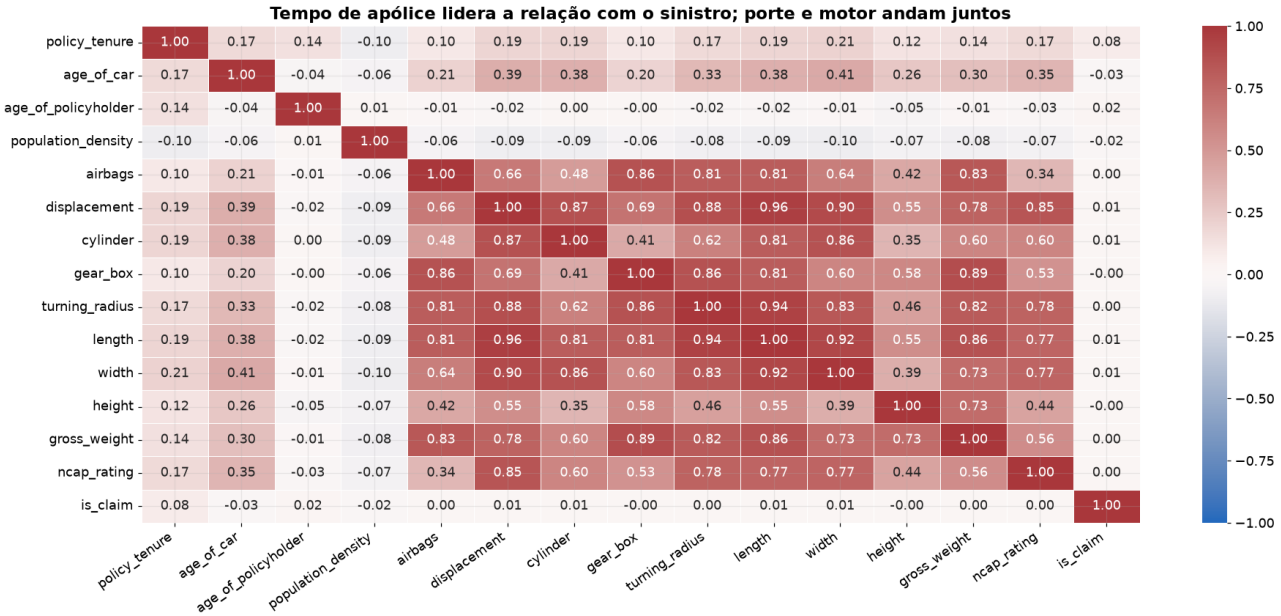
1. Problema de negócio

Uma seguradora precisa decidir, na emissão e renovação da apólice, qual a probabilidade de cada segurado acionar o seguro nos próximos 6 meses. O score apoia precificação baseada em risco, priorização de apólices para revisão manual/triagem de fraude e redução de sinistralidade sem rejeitar bons clientes. A base (Kaggle Car Insurance Claim Prediction) tem 58.592 apólices e 44 colunas — perfil do segurado, características do veículo e o alvo binário **is_claim** — com forte desbalanceamento: apenas 6,4% das apólices acionam o seguro em 6 meses.

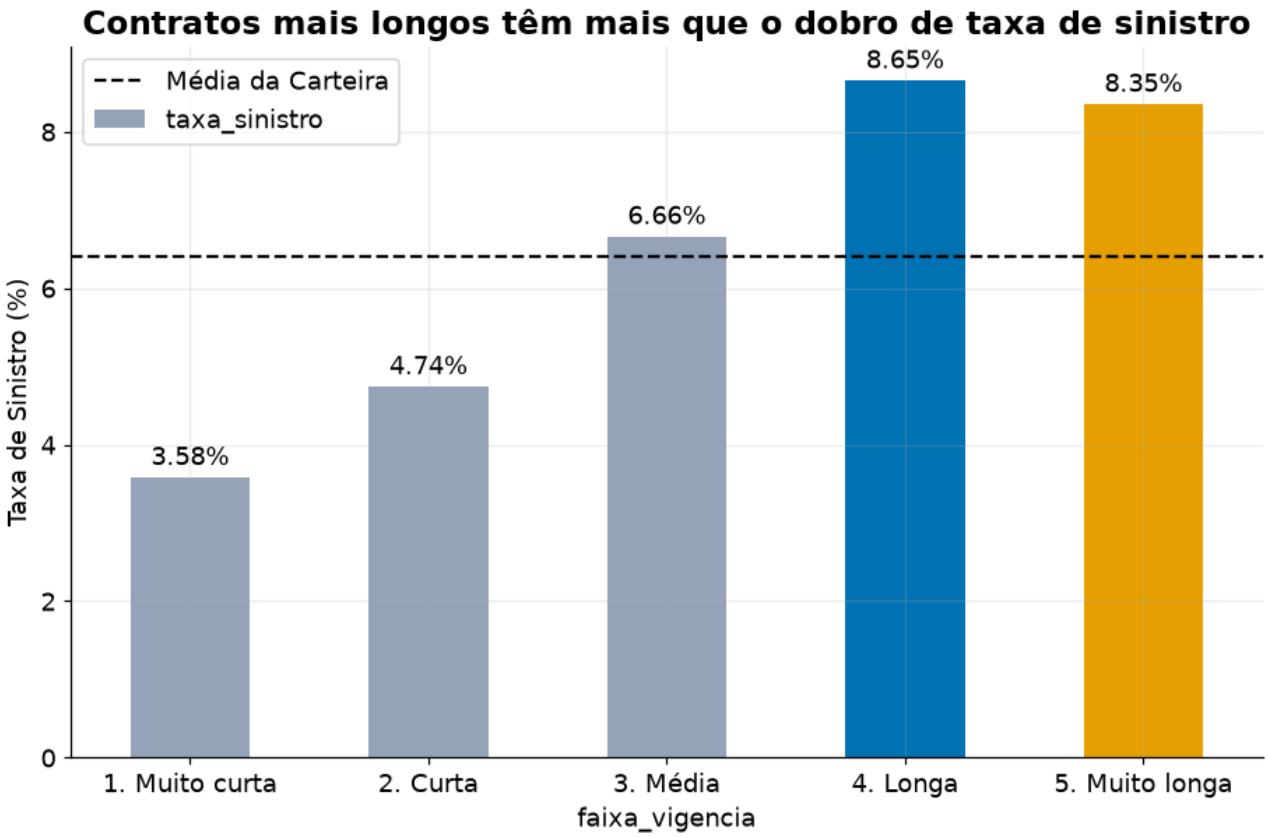
2. Principais insights (EDA)



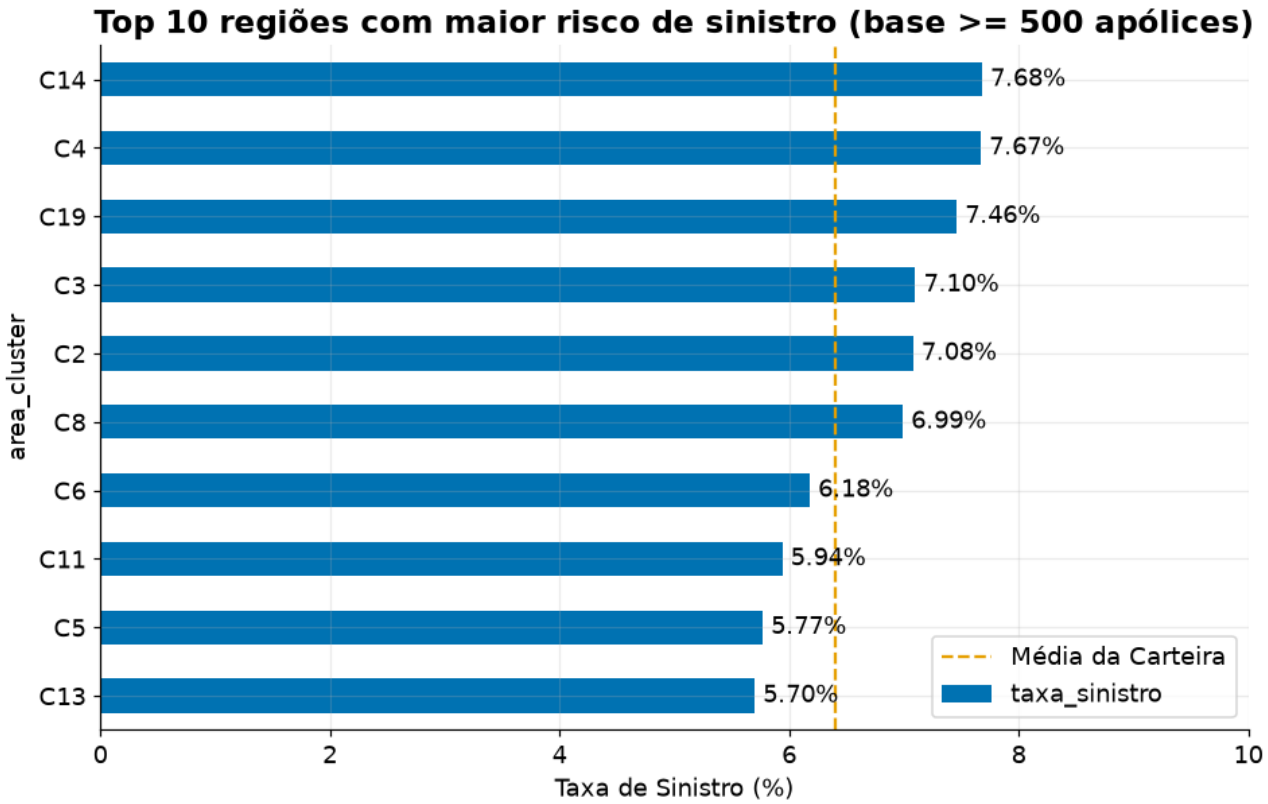
Alvo raro e desbalanceado: só 6,4% das apólices (3.748 de 58.592) acionam o seguro em 6 meses.



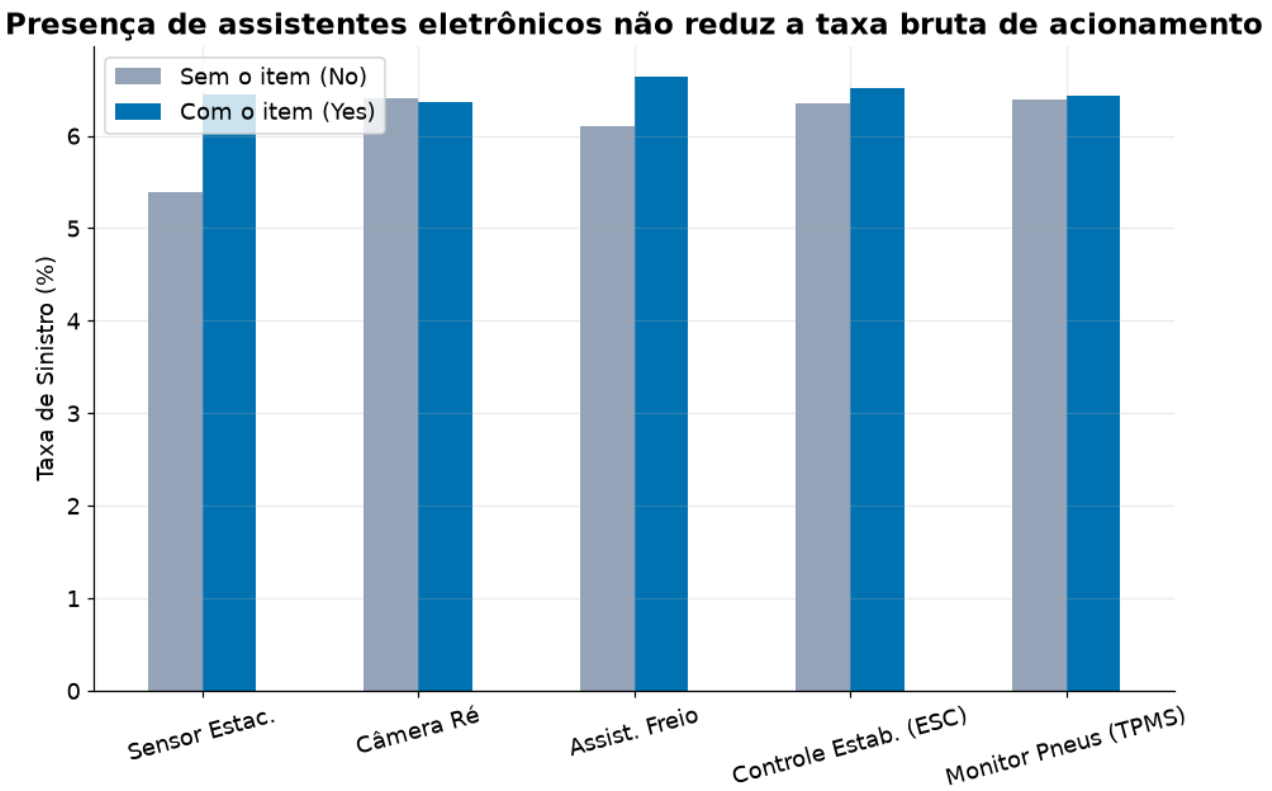
policy_tenure é a variável com maior correlação com is_claim (+0,08), ainda fraca. As variáveis de porte/motor do veículo são fortemente correlacionadas entre si (até 0,96), mas quase 0 com o alvo.



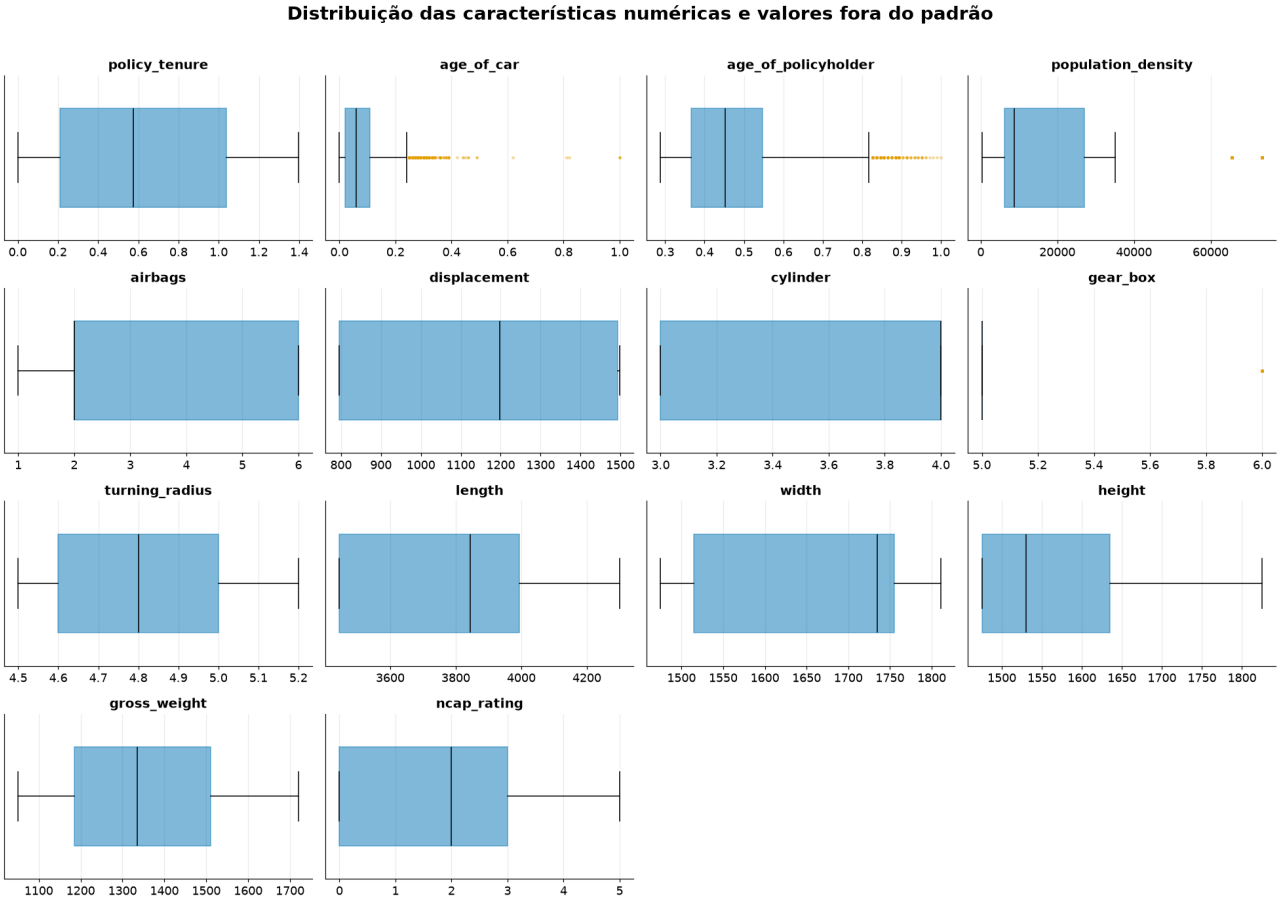
Tempo de apólice é o sinal mais forte: apólices longas/muito longas têm taxa de sinistro de 8,3-8,7%, mais que o dobro das muito curtas (3,6%).



Risco varia por região: os clusters C14, C4 e C19 têm taxa de sinistro acima de 7,4% vs. 6,4% da carteira.



Itens de segurança eletrônicos (sensor de estacionamento, câmera de ré, ESC, TPMS) não reduzem a taxa bruta de sinistro.



Outliers tratados por z-score (limitados a 3 desvios-padrão, sem remover apólices) em age_of_car, age_of_policyholder e population_density.

3. Abordagem estatística (GLM / Poisson)

notebooks/glm_poisson.ipynb compara 5 modelos generalistas da família GLM (statsmodels), em um for: Poisson, Binomial-Logit, Binomial-Probit, Binomial-Cloglog e Binomial Negativa.

Protocolo sem vazamento. A divisão treino/teste (80/20) vem antes de tudo. Limites de outlier, correlações, categorias das dummies, escolha de variáveis e limiar de decisão vêm só do treino; as escolhas são feitas por validação cruzada 5-fold no treino e o teste só é reportado. Nenhuma coluna nova é criada na base: só seleção de colunas existentes e codificação 0/1 das categóricas e Sim/Não.

Variáveis. policy_tenure (maior correlação positiva com o alvo), age_of_policyholder, age_of_car (correlação negativa, mas 2º sinal mais forte), cylinder e is_parking_sensors (veículo: correlação positiva acima de 2/raiz(n), sem colinearidade e com informação nova), segment, transmission_type e area_cluster.

Resultado. A versão inicial não dava policy_tenure aos 4 modelos não-Poisson; corrigido isso, eles vão de ROC-AUC 0,546 para 0,610 na validação cruzada e de 0,555 para 0,586 no teste. O Poisson praticamente não muda. As 5 famílias ficam indistinguíveis. Marcando 45% da carteira, o modelo pega ~55% dos sinistros com precisão de ~8% (taxa base 6,4%).

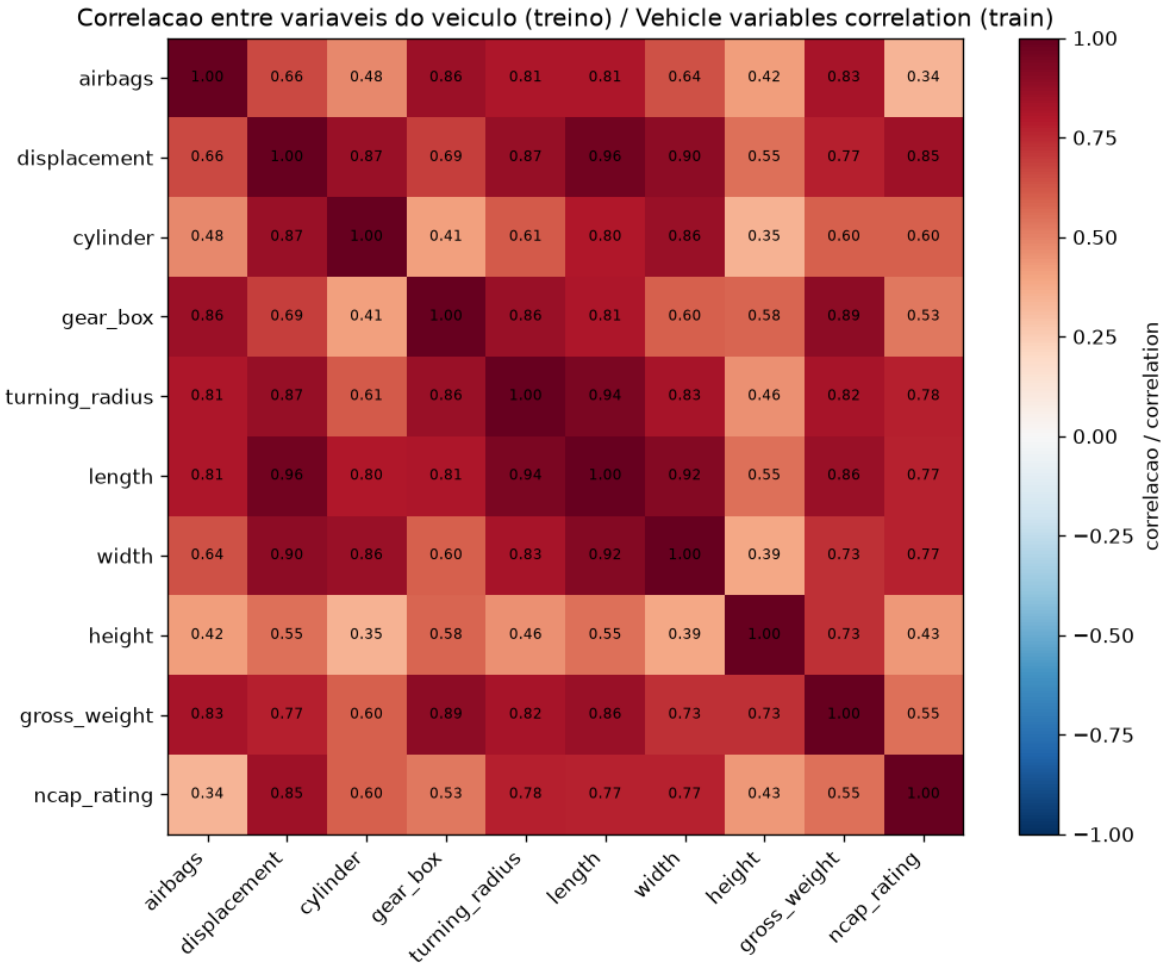
Limite. Uma árvore com as mesmas colunas do GLM chega a ~0,65: a diferença é a forma linear, não falta de informação. O caso mais claro é age_of_car (carros com idade 0 têm ~10% de sinistro, contra 4,5-7% nas outras faixas); representar isso exige uma coluna nova.

modelo	roc_auc	pr_auc	recall	precisao	sinalizadas	cv_roc_auc
Poisson	0.5857	0.0863	0.5520	0.0803	0.4399	0.6104
Binomial - Logit	0.5857	0.0864	0.5520	0.0802	0.4403	0.6104
Binomial - Probit	0.5857	0.0862	0.5493	0.0799	0.4399	0.6106
Binomial - Cloglog	0.5857	0.0863	0.5520	0.0803	0.4400	0.6104
Binomial Negativa	0.5856	0.0863	0.5520	0.0803	0.4401	0.6104

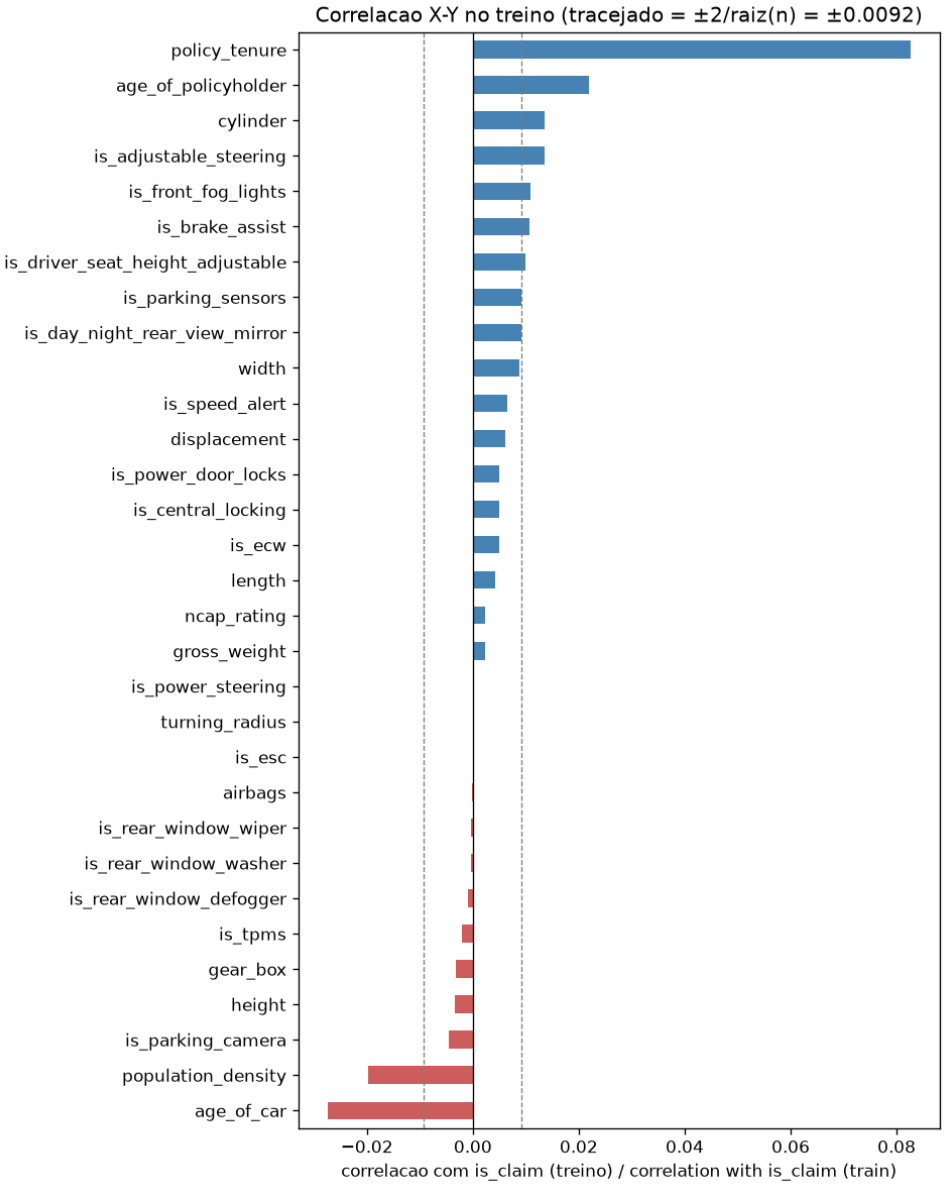
Antes vs. depois e referências (mesmo protocolo)

configuracao	cv_roc_auc	teste_roc_auc	teste_pr_auc	recall_corte_20
antes - Poisson	0.6050	0.5862	0.0811	0.2733
antes - Binomial - Logit	0.5460	0.5550	0.0742	0.2413
antes - Binomial - Probit	0.5461	0.5550	0.0742	0.2427
antes - Binomial - Cloglog	0.5460	0.5549	0.0742	0.2413
antes - Binomial Negativa	0.5460	0.5549	0.0742	0.2413
ablacao - antes + policy_tenure (Logit, sem area_cluster)	0.6077	0.5900	0.0825	0.2800
depois - Poisson	0.6104	0.5857	0.0863	0.2667
depois - Binomial - Logit	0.6104	0.5857	0.0864	0.2653
depois - Binomial - Probit	0.6106	0.5857	0.0862	0.2653
depois - Binomial - Cloglog	0.6104	0.5857	0.0863	0.2667
depois - Binomial Negativa	0.6104	0.5856	0.0863	0.2693
decisao - Poisson so com offset (policy_tenure fora dos preditores)	0.6072	0.5862	0.0840	0.2600
decisao - Logit sem age_of_car	0.6014	0.5724	0.0820	0.2493
referencia - arvore com as mesmas colunas do GLM	0.6530	0.6590	0.1127	0.3400

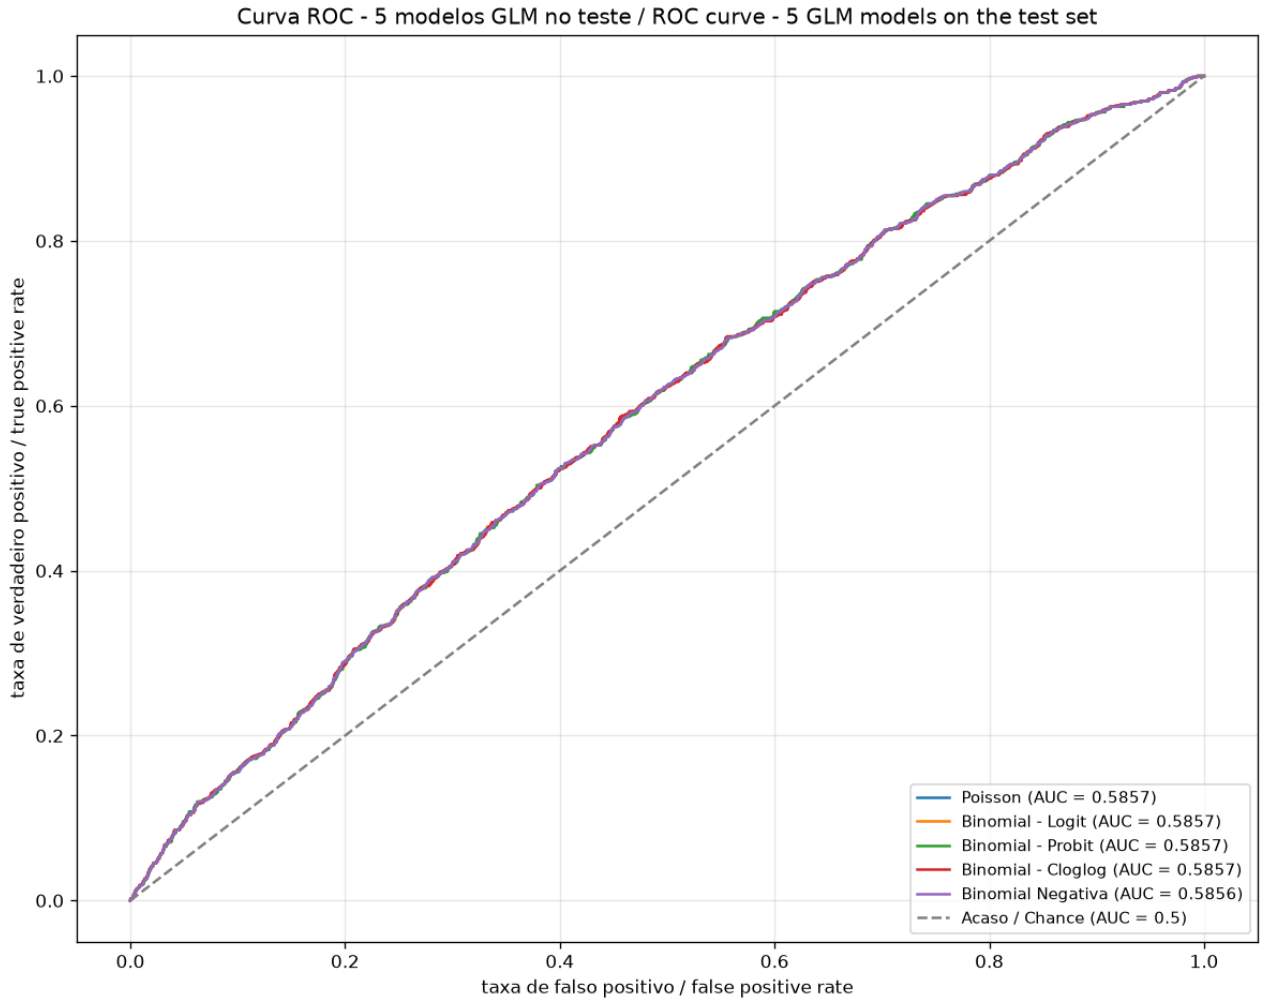
referencia - arvore com todas as colunas	0.6521	0.6584	0.1113	0.3800



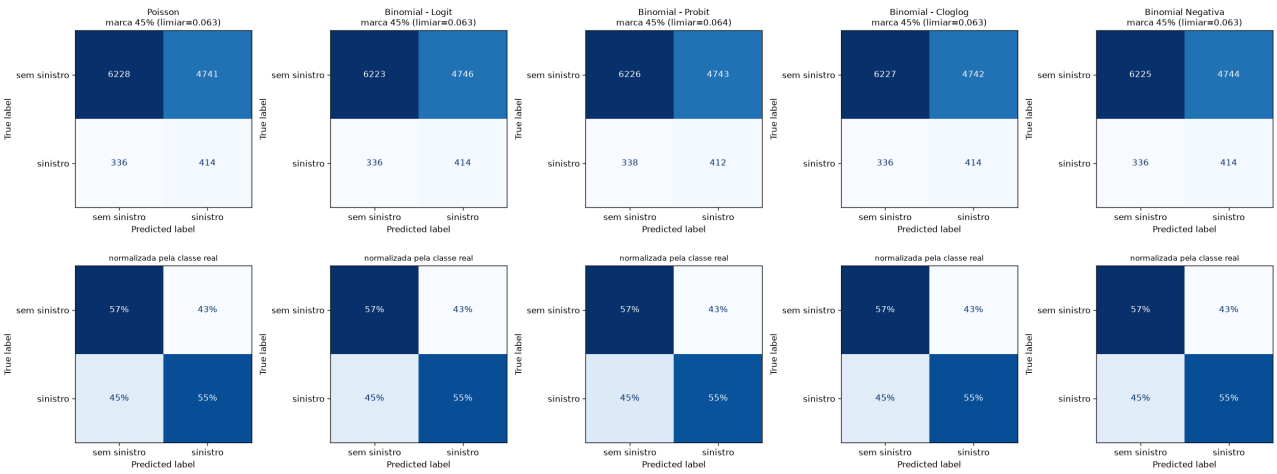
Correlação entre as variáveis numéricas do veículo (treino).



Correlação de cada variável com is_claim no treino (X-Y); tracejado = ±2/raiz(n).



Curva ROC dos 5 modelos GLM na base de teste.



Matrizes de confusão dos 5 modelos GLM, todos marcando 45% da carteira (corte definido no treino).

4. Modelos de produção (árvore/boosting)

notebooks/model_ml.ipynb treina e compara 10 modelos (mesmas colunas, label-encoded) e notebooks/pipeline_ml.ipynb ajusta 2 pipelines HistGradientBoosting tunados (RandomizedSearchCV / GridSearchCV). Os artefatos de produção (.joblib) ficam em models/. O limiar de negócio padrão é **0,55** de probabilidade de sinistro (models/limiar_negocio.joblib).

modelo	roc_auc	pr_auc	acuracia	f1
HistGradientBoosting	0.6493	0.1071	0.7796	0.1709
CatBoost	0.6476	0.1062	0.7794	0.1701
Gradient Boosting	0.6454	0.1040	0.7779	0.1645
Random Forest	0.6417	0.1055	0.7779	0.1645
XGBoost	0.6371	0.1008	0.7741	0.1501
AdaBoost	0.6369	0.1003	0.7766	0.1597
LightGBM	0.6341	0.1018	0.7734	0.1477
Decision Tree	0.6341	0.1000	0.7730	0.1461
Extra Trees	0.6199	0.0912	0.7707	0.1372
Logistic Regression	0.6125	0.0906	0.7732	0.1469

5. Arquitetura MLOps

car_insurance_claim/ é o pacote compartilhado por todos os componentes: modeling/predict.py (inferência — carrega models/, aplica os mesmos LabelEncoders do treino, mapeia categorias não vistas, aplica o limiar de negócio), modeling/train.py (retreino dos 10 modelos + log no MLflow, chamado pelo Airflow) e mlops/ (utilitários de MLflow e backfill de métricas históricas).

Componente	Porta	Papel
Streamlit (app/)	8501	Seleção de modelo, upload de CSV/parquet, previsão em lote, comparativo de modelos
MLflow (docker/mlflow.Dockerfile)	5000	Tracking de métricas, registro de modelos, histórico de execuções
Airflow (airflow/)	8080	DAG semanal: retreina os 10 modelos a partir de data/raw e loga no MLflow
Postgres	interno	Metadata store do Airflow

6. Como executar

```
docker compose up -d --build (Streamlit + MLflow)
docker compose exec streamlit python -m car_insurance_claim.mlops.backfill (popula o
histórico do MLflow)
docker compose -f docker-compose.airflow.yml up -d --build (Airflow, opcional)
```